Guía de estudio para la defensa · variables, modelo y experimentos

Equipo Alpha Centauri · Rocket Landing · noviembre de 2026. Documento interno para tener claro, antes de exponer, cómo se modela cada variable, qué ve y qué decide el agente, cómo se premia y cuándo termina una época, qué cambia entre niveles y entre experimentos, y qué números conviene recordar. Todo sale del código y de las fichas versionadas: ambiente-v0.1.md, ambiente-v0.4.md, ambiente-v0.5.md, experimento-2.md, `configs/*.json` y EXPERIMENTOS.md.

1. El mapa en una frase

Un **ambiente** Gymnasium simula un cohete que cae desde 600 m con viento, atmósfera y combustible limitado; un **agente** (Q-learning al principio, PPO después) decide cada paso el empuje y la inclinación; una **recompensa** con forma de potencial lo guía hacia la plataforma y un premio final decide si la misión se cumplió; cada **nivel** sube la complejidad (pasarela, viento fuerte) con una versión nueva del ambiente; cada **experimento** agrupa ejecuciones que responden una pregunta cambiando una variable a la vez; el **pipeline** entrena, evalúa con una suite fija, decide con un criterio escrito de antemano y publica el modelo recomendado.

Pieza	Nivel 1	Nivel 2 (v1)	Nivel 3 (v1)
Ambiente	`RocketLanding3D-v0` 0.1.1	`RocketLanding3D-N2-v1` 0.4	`RocketLanding3D-N3-v1` 0.5
Qué añade	misión base	pasarela a 180 m con una sola abertura desplazada	viento 0–15 m/s y ráfagas de 3 m/s sobre el mismo mundo
Observación	16 valores	20 valores	20 valores (misma familia que N2)
Acción	5 valores (la red decide 3)	igual	igual
Resultados posibles	aterrizaje, fuera de plataforma, choque, sin pasos, fuera de zona	+ colisión	igual que N2
Experimentos	1 (Q-learning), 2 (PPO)	3 (torres, retirado), 5 (pasarela)	4 (torres, retirado), 6 (pasarela)
Recomendado	`ppo-v2-v0.1-s1` 99 %	`ppo-pasarela-transfer-1m5-v0.4-s2` 100 %	`ppo-pasarela-viento-transfer-1m5-desde-s2-v0.5-s0` 97,5 %

2. El mundo: cómo se modela cada variable

Unidades SI en todo el ambiente. El eje z apunta hacia arriba; la plataforma está en el origen.

Variable	Cómo se modela	Valores
Posición (x, y, z)	masa puntual integrada con Euler explícito cada 0,1 s	salida en z = 600 m sobre x, y ∈ [−50, 50] m; zona de vuelo: cilindro de 300 m de radio y 1200 m de techo
Velocidad (vx, vy, vz)	a = (empuje + arrastre)/m + gravedad; v ← v + a·Δt	salida: vz ∈ [−20, −15] m/s, vx, vy ∈ [−3, 3] m/s
Masa m	1000 kg en seco + combustible	combustible inicial 500 kg; consumo $\dot{m} = T/(I_{sp} \cdot g_0)$, I_{sp} = 250 s
Empuje T	T = (27 000 N − p(z)·0,02 m²) · acelerador, en la dirección del eje; solo con motor encendido, combustible y sin sobrecalentar	≈ 25 kN al nivel del mar; relación empuje/peso 1,7 lleno y 2,5 vacío
Arrastre D	D = −½ ρ(z) C_d A |v − w| (v − w), C_d = 0,8, A = 3 m²	es la **única vía por la que el viento mueve el cohete**: 10 m/s de viento ≈ 130 N ≈ 0,09 m/s²
Gravedad	−m·g_0 en z, g_0 = 9,80665 m/s²	
Atmósfera	ISA desde el suelo: T(z) = T_0 − 0,0065·z; p(z) = p_0·(T/T_0)^(g_0/(R·0,0065)); ρ = p/(R·T)	T_0 ∈ [263, 313] K (−10 a 40 °C) y p_0 ∈ [98, 104] kPa, sorteados por época; la densidad varía un 25 % entre épocas
Viento medio w(z)	perfil de potencia: w(z) = w_{10} · (max(z, 1)/10)^(1/7), dirección φ fija por época	w_{10} ∈ [0, 10] m/s en N1 y N2; [0, 15] en N3; a 600 m el viento es 1,8 veces el de 10 m
Ráfagas g_r	proceso de Ornstein-Uhlenbeck: dg = −g/τ·dt + σ·√(2dt/τ)·ξ, τ = 3 s; vertical ×0,3	σ = 1,5 m/s en N1 y N2; 3 m/s en N3
Temperatura del motor T_m	dT_m/dt = 30·acelerador − 0,05·(T_m − T_aire)	se bloquea a 900 K hasta bajar de 800 K; en la práctica llega a unos 600 K
Inclinación θ	el eje del cohete sigue instantáneamente a la dirección del empuje (sin dinámica de rotación); θ = arccos(dz)	límite de aterrizaje 10°
Pasos k	cada paso del agente dura hasta que el cohete se desplaza 20 m en vertical o pasan 2 s, lo que ocurra antes (7 a 20 subpasos de física)	50 pasos como máximo, es decir, 100 s de vuelo

Perturbación / incidente. `reset(options={"viento": 15})` fija w_{10} = 15 m/s con dirección aleatoria: fuera del rango de entrenamiento de N1 y N2, dentro del de N3. Es la segunda condición de la suite de evaluación y el "incidente" de la rúbrica.

3. Observación: lo que ve el agente

Vector en unidades físicas; PPO lo normaliza con `VecNormalize` (media y varianza móviles, recorte a ±10). El agente **no** ve las ráfagas futuras, el bloqueo térmico, la dirección media del viento ni el tiempo absoluto.

Índice	Nivel 1 (16 valores)	Unidad
0–2	x, y, z (posición respecto al centro de la plataforma)	m
3–5	vx, vy, vz	m/s
6–8	viento en la posición del cohete (medio + ráfaga)	m/s
9, 10	temperatura y presión del aire	K, kPa
11	temperatura del motor	K
12	combustible restante	fracción 0–1
13	motor encendido	0/1
14	pasos restantes	fracción 0–1
15	inclinación del eje	grados

Índice	Niveles 2 y 3 con pasarela (0.4 y 0.5): 16 + 4	Unidad
16, 17	o_x − x, o_y − y: posición relativa del **objetivo de la fase** (el centro de la abertura mientras el cohete está por encima de la pasarela; la plataforma una vez debajo)	m
18	H − z: altura que queda hasta la pasarela (negativa una vez cruzada)	m
19	r_a − d_a: margen hasta el borde de la abertura (positivo dentro de ella)	m

Con las torres retiradas (0.2 y 0.3) eran 25 valores: los 16 de N1 más, por torre, x_k − x, y_k − y, h_k − z. Un modelo de N1 tiene una red de 16 entradas: para jugar en N2 o N3 se le recorta la observación con `AdaptadorN1` y vuela **a ciegas** respecto al obstáculo. Eso mide la dificultad del nivel (5 % bajo la pasarela).

Por qué "objetivo de la fase" y no "posición de la abertura". El primer intento del nivel 2 v1 ponía la abertura fija en las entradas 16 y 17 y la red heredada seguía volando hacia la plataforma: 2 % a los 320 000 pasos, abortado. Darle a la red el siguiente punto de paso, como un sistema de navegación, y heredar en esas entradas los pesos de la posición hizo que la política de partida ya aterrizara el 35 % sin entrenar.

4. Acción: lo que decide el agente

Acción del entorno (contrato, 5 valores continuos): motor encendido (> 0) o apagado; acelerador en [0, 1] como fracción del empuje máximo; dirección del empuje (x, y, z), que el entorno normaliza. No hay torque: el eje sigue al empuje.

Los agentes no emiten esos 5 valores directamente (salvo el experimento fallido `ppo-v0.1-s0`). Cada uno tiene su **parametrización**, y esa elección fue la decisión más importante del proyecto:

Agente	Qué decide	Traducción a la acción del entorno
Q-learning (exp. 1)	motor: apagado o empuje ×0,6, ×0,9, ×1,0, ×1,1, ×1,4 **el peso actual**; dirección: recto o inclinado 5,7° hacia ±x o ±y	el acelerador se calcula con la masa y la presión observadas, así "×1,0" siempre significa flotar
PPO acción cruda (`ppo-v0.1-s0`)	los 5 valores del entorno	ninguna; **0 % de aterrizajes**: aprende a acercarse pero nunca a frenar
PPO relativa v1 (`ppo-rel-v0.1-s0`)	empuje/peso en [0, 1,6]; inclinación ±0,3 por eje (hasta 23°)	**0 %**: frena perfecto (0,3 m/s) pero llega inclinado 17° y choca por inclinación
PPO relativa v2 (todo lo demás)	3 valores en [−1, 1]: a_0 empuje, a_1 y a_2 inclinación	empuje/peso = 1 + a_0 (máximo 1,6; por debajo de 0,05 el motor se apaga); inclinación = $a_1 \cdot 0{,}12$ y $a_2 \cdot 0{,}12$ (≤ 9,6° combinados, por debajo del límite de 10°). La acción 0 es "flotar recto": la política inicial no cae

Lecciones que conviene decir en voz alta: la parametrización decide si el problema es aprendible; los límites de la acción deben respetar las reglas del aterrizaje; arrancar flotando hace útil la exploración desde la primera época; los dos fracasos están versionados como evidencia.

5. Recompensa

Dos partes: **por paso**, una diferencia de potencial menos el combustible gastado; **al terminar**, un premio o castigo según el resultado.

Por paso: $r = \Phi(s') - \Phi(s) - 0{,}1 \cdot$ kg de combustible gastados en el paso.

```
Φ(s) = −d_obj/5 − v_h − |vz − v_seg(z)| − z/10 [− 8·c en N2 y N3]
v_seg(z) = −clip(0,08·z, 1,5, 30)  m/s: bajar rápido arriba, despacio cerca del suelo
```

- d_obj: distancia horizontal al objetivo. En N1 es la plataforma. Con pasarela es la abertura mientras el cohete está encima y la plataforma una vez debajo.
- v_h: velocidad horizontal. |vz − v_seg|: cuánto se aparta de la velocidad de descenso segura. z/10: siempre empuja a bajar.
- c (solo con pasarela): castigo de proximidad, c = 1 − (z − H)/20 en los 20 m por encima de la pasarela y fuera de la abertura; vale hasta 8 puntos.

Por ser un potencial, la suma de la época vale Φ(final) − Φ(inicio), unos +80 puntos como máximo, **sea cual sea el camino**: flotar o dar vueltas no suma. El combustible resta hasta 50 puntos si se vacía el depósito.

Al terminar:

Resultado	Cuándo	Puntos	Gymnasium
aterrizaje	contacto con |vz| ≤ 3 m/s, v_h ≤ 2 m/s, inclinación ≤ 10° y a ≤ 10 m del centro	**+100**	`terminated`
fuera de plataforma	contacto suave (las tres condiciones) pero a más de 10 m del centro	−50	`terminated`
choque	contacto que incumple alguna condición de suavidad	−100	`terminated`
fuera de zona	d_h > 300 m o z > 1200 m	−100	`terminated`
colisión (N2, N3)	cruzar el plano de la pasarela fuera de la abertura, o tocar un pilar (radio del fuselaje 3 m)	−100	`terminated`
sin pasos	agotar los 50 pasos sin tocar el suelo	−100	`truncated`

Por qué estos valores: aterrizar y chocar son simétricos (±100) y dominan sobre la aproximación (+80) y el combustible (−50), así que la única manera de acabar con recompensa alta es aterrizar. Un aterrizaje típico vale unos +150; un choque, unos −73; agotar pasos, unos −95. Las bandas no se solapan.

Trampas comprobadas con políticas fijas. Flotar da −205 (el viento saca al cohete de la zona y gasta 413 kg); caída libre, −113 (choca siempre); subir siempre, −261. Posarse suave fuera de la plataforma puede acabar cerca de cero (media +0,8): es la única trampa que queda abierta y la métrica "fuera de plataforma" la vigila (5 % con el Q-learning, 0–1 % con PPO).

6. Truncamiento frente a terminación

Gymnasium distingue dos formas de acabar una época y el contrato del ambiente las respeta desde la versión 0.1.1:

- `terminated=True`: el cohete llegó a un **estado final**: tocó el suelo (aterrizaje, fuera de plataforma, choque), salió de la zona o chocó con la pasarela. No existe un estado siguiente desde el que seguir.
- `truncated=True`: la época la corta un **límite externo**: los 50 pasos. El cohete sigue en el aire; el estado no es final, pero no se le deja continuar. La penalización (−100) es la misma que la de un fracaso, para que esperar nunca compense.

Por qué importa: los algoritmos que calculan el retorno con *bootstrap* (PPO estima el valor del estado siguiente) deben tratar distinto un corte externo de un estado final; mezclarlos sesga la función de valor. El ambiente no usa `max_episode_steps` de Gymnasium: cuenta sus propios pasos y devuelve `truncated` él mismo. Hay pruebas de contrato en `tests/test_ambiente.py` para los dos casos. La versión del ambiente pasó de 0.1 a 0.1.1 (tercer número) porque la señal cambió pero las reglas y la recompensa no: `compatible()` compara solo mayor.menor, así que los modelos de 0.1 siguen siendo válidos.

Dato útil: en el recomendado de N1 con viento de 15 m/s, 49 de los 56 fracasos son "sin pasos": el modelo se queda luchando contra el viento sin llegar a posarse. Eso es truncamiento, no choque.

7. Qué cambia de una versión del ambiente a otra

Versión	Nivel	Qué cambia respecto a la anterior	Estado
0.1 → 0.1.1	N1	solo la señal: "sin pasos" pasa a `truncated`	vigente
0.2	N2 v0	tres torres (radios 7 m, alturas 420, 360 y 300 m) alrededor de la plataforma; observación 25; resultado "colisión"; castigo de proximidad	retirado el 6 de noviembre
0.3	N3 v0	las torres con viento 0–15 m/s y ráfagas 3 m/s; misma observación que 0.2	retirado
0.4	N2 v1	**pasarela**: disco de 90 m de radio a 180 m de altura, 3 m de grosor, abertura de 16 m de radio centrada en (28, 12) m, cuatro pilares de 2,5 m en el borde; observación 16 + 4 con el objetivo de la fase; potencial con d_obj por fases y castigo c; herencia de pesos en la transferencia	vigente
0.5	N3 v1	0.4 con viento 0–15 m/s y ráfagas 3 m/s; nada más cambia	vigente

Por qué se cambiaron las torres por la pasarela: con las torres la ruta recta solo cruzaba una torre en el 30 % de las salidas (el modelo de N1 a ciegas conservaba el 72 %); con la pasarela la ruta recta choca siempre salvo que la salida caiga sobre la abertura (el modelo de N1 a ciegas baja a 5 %). La decisión es inevitable y se ve en el replay: entrar por la abertura y trasladarse 30 m por debajo mientras se frena desde 180 m (v_seg(180) = 14,4 m/s).

8. Los agentes y sus hiperparámetros

Q-learning (experimento 1). Dos tablas pequeñas, 297 valores en total: la del motor indexada por altitud (6 intervalos: 20, 60, 150, 350, 600 m) y velocidad vertical (7 intervalos); la de dirección indexada por la deriva prevista en 4 s en cada eje horizontal (3 intervalos: a un lado, centrado, al otro lado). α de 0,1 a 0,01, γ = 0,99, ε de 1 a 0,02 en el 60 % de las 5000 épocas; evaluación cada 250 épocas en 50 sin explorar y se guarda la mejor. Resultado: 78,5 % (38 % con viento). Primer aterrizaje en la época 1785.

PPO (Stable-Baselines3, experimentos 2 a 6). Misma receta en todas las ejecuciones; lo que cambia entre experimentos es el ambiente, el modelo de partida, el presupuesto y la semilla.

Hiperparámetro	Valor	Qué controla
red (`net_arch`)	MLP 128 × 128, política y valor separadas	capacidad de la función

Hiperparámetro	Valor	Qué controla
`n_envs`	8 entornos en paralelo	muestras por actualización
`n_steps`	256 por entorno (2048 por actualización)	tamaño del lote de experiencia
`batch_size` · `n_epochs`	256 · 10	cuántas veces se reutiliza cada lote
`learning_rate`	$3{\cdot}10^{-4}$	tamaño del paso de optimización
`gamma` γ	0,99	descuento: con 50 pasos por época, casi sin descuento
`gae_lambda` λ	0,95	sesgo frente a varianza en la ventaja (GAE)
`clip_range`	0,2	cuánto puede cambiar la política por actualización
`ent_coef`	0,005	bonificación de entropía: mantiene exploración
`log_std_init`	−0,5 (desviación inicial ≈ 0,6)	ruido inicial de la política en acciones de [−1, 1]
normalización	`VecNormalize` de observaciones y recompensas, recorte ±10	la red ve entradas comparables (metros, kelvin, fracciones)
evaluación periódica	cada 20 000 pasos, 50 épocas sin ruido con semillas desde 20 000 000; se guarda la mejor	elección del punto de control
presupuesto	600 000 pasos (N1: ≈ 16 000 épocas, 11 min) o 1 500 000 (N2, N3: ≈ 42 000 épocas)	
semillas	0, 1, 2; cada entorno paralelo usa semilla$\cdot 10^6$ + k	réplicas

Transferencia (`--desde`). Se copian los pesos de la misma forma; en la primera capa, las columnas de las entradas que ya existían se copian y las nuevas empiezan en cero, así la red arranca comportándose como la original. La normalización de observaciones se copia para las entradas comunes. Con la pasarela, además, las entradas 16 y 17 (objetivo − posición) **heredan los pesos de x e y con signo cambiado** y las de x e y se anulan: la política de partida vuela hacia el objetivo de la fase desde el primer paso y solo tiene que aprender a cruzar frenando.

9. Los seis experimentos: pregunta, variable que cambia, resultado

Cada ejecución tiene en `configs/<run_id>.json` su hipótesis, el cambio frente a su baseline, el presupuesto y la decisión con fecha. Regla de diseño: **una variable a la vez**.

Experimento 1 · Q-learning en el nivel 1 (ambiente 0.1)

Pregunta: ¿se puede aprender a aterrizar con un modelo tabular pequeño? Fija el baseline y las métricas. Referencias no aprendidas: agente aleatorio 0/20, controlador heurístico a mano 20/20.

Ejecución	Cambio	Aterrizajes · con viento 15
`base-v0.1-s0`	primer modelo aprendido	78,5 % · 38 %

Experimento 2 · PPO en el nivel 1 (0.1, 0.1.1)

Pregunta: ¿una red neuronal supera al Q-learning? ¿Qué parametrización de la acción lo hace aprendible y cuánto varía entre semillas?

Ejecución	Cambio frente a la anterior	Aterrizajes · con viento	Decisión
`ppo-v0.1-s0`	tabla → red MLP 128×128; acción cruda; 400 000 pasos	0 % · 0 %	rechazada
`ppo-rel-v0.1-s0`	acción relativa v1 (empuje/peso directo, inclinación ±23°); 600 000 pasos; entropía 0,005	0 % · 0 %	rechazada (llega inclinada 17°)
`ppo-v2-v0.1-s0`	acción relativa v2 (centrada en flotar, inclinación ≤ 9,6°); desviación inicial 0,6	97 % · 62,5 %	referencia
`ppo-v2-v0.1-s1`	solo la semilla (1)	**99 % · 72 %**	**recomendado de N1** (pipeline, 5 de noviembre)
`ppo-v2-v0.1-s2`	solo la semilla (2)	97,5 % · 71,5 %	rechazada (no mejora en 2 puntos)

Tres semillas: 97,8 ± 1,0 %. La cifra honesta de la configuración es la media; el recomendado es la mejor de tres por el criterio del pipeline.

Experimento 3 · Nivel 2 con torres (0.2, retirado)

Pregunta: con una decisión nueva (por qué hueco entrar), ¿aprende PPO desde cero o hay que partir del modelo de N1? ¿Cuánto presupuesto exige?

Ejecución	Cambio	Aterrizajes · con viento · colisiones
`ppo-n2-v0.2-s0`	misma receta de N1, desde cero	8 % · 1,5 % · 54
`ppo-n2-transfer-v0.2-s0`	transferencia desde `ppo-v2-v0.1-s0`	76,5 % · 42 % · 42
`ppo-n2-transfer-1m5-v0.2-s0`	solo el presupuesto: 1,5 M de pasos	86 % · 55,5 % · 27

Ejecución	Cambio	Aterrizajes · con viento · colisiones
`-s1`, `-s2`	solo la semilla	93,5 % y 85,5 %; tres semillas 88,3 ± 4,5 %

Lección: desde cero no aprende; la transferencia lo hace abordable; esquivar exige anticipar la ruta y 600 000 pasos no bastan.

Experimento 4 · Nivel 3 con torres (0.3, retirado): incidente e intervención

Pregunta: cuando cambian las condiciones de operación, ¿cuánto se degrada el modelo de N2 y lo recupera reentrenarlo? ¿Desde qué modelo conviene partir?

Ejecución	Cambio	Aterrizajes · con viento · colisiones
(incidente) recomendado de N2 jugando en N3	ninguno: medición	72 % (−11 puntos frente a su nivel)
`ppo-n3-transfer-v0.3-s0`	reentrenar en N3 desde el recomendado de N2, 600 000 pasos	81,5 % · 74,5 % · 37 (rechazada: más colisiones)
`ppo-n3-transfer-1m5-v0.3-s0`	solo el presupuesto: 1,5 M	86,5 % · 67,5 % · 24
`ppo-n3-transfer-1m5-desde-s1-v0.3-s0`	solo el modelo de partida: N2-s1 (nuevo recomendado de N2)	92 % · 79 % · 15
`-s1`, `-s2`	solo la semilla	91,5 % y 84,5 %; tres semillas 89,3 ± 4,2 %

Aquí se demostró el **rollback en producción**: catálogo v8 → v9 (restaurar el anterior) → v10 (volver al recomendado), con `comprobar_api.py` como evidencia.

Experimento 5 · Nivel 2 v1: pasarela (0.4)

Pregunta: con el obstáculo acordado por el equipo, ¿aprende PPO a entrar por la abertura y volver al centro partiendo del modelo de N1?

Ejecución	Cambio	Aterrizajes · con viento · colisiones	Decisión
intento abortado (sin run_id)	abertura fija en la observación, transferencia simple	2 % a los 320 000 pasos	abortado; MLflow limpiado; documentado en la ficha
`ppo-pasarela-transfer-1m5-v0.4-s0`	observación "objetivo de la fase" + herencia de pesos; desde `ppo-v2-v0.1-s1`; 1,5 M	91,5 % · 30 % · 14	seleccionada frente al 5 % a ciegas (catálogo v11)
`-s1`	solo la semilla	97,5 % · 52 % · 4	seleccionada: mejora 6 puntos

Ejecución	Cambio	Aterrizajes · con viento · colisiones	Decisión
`-s2`	solo la semilla	**100 % · 68 % · 0**	**recomendado de N2**

Tres semillas: 96,3 ± 4,4 %. La variabilidad con viento (30 a 68 %) es el incidente que el nivel 3 convierte en operación normal.

Experimento 6 · Nivel 3 v1: pasarela con viento fuerte (0.5)

Pregunta: con viento de hasta 15 m/s y ráfagas dobles, ¿cuánto se degrada el modelo de la pasarela y lo recupera reentrenarlo?

Ejecución	Cambio	Aterrizajes · con viento · colisiones	Decisión
(incidente) N2-s0, N2-s1, N2-s2 jugando en N3 v1	medición	64,5 % (−27), 85 % (−12,5), 93,5 % (−6,5)	fallo principal: colisión con la pasarela
`ppo-pasarela-viento-transfer-1m5-v0.5-s0`	reentrenar en N3 v1 desde N2-s0; 1,5 M	94,5 % · 65,5 % · 6	seleccionada frente al 64,5 % (catálogo v12)
`-s1`, `-s2`	solo la semilla	94 % y 92,5 %; tres semillas 93,7 ± 1,0 %	rechazadas: no mejoran a s0
`ppo-pasarela-viento-transfer-1m5-desde-s2-v0.5-s0`	solo el modelo de partida: N2-s2 (nuevo recomendado de N2)	**97,5 % · 85,5 % · 3**	**recomendado de N3** (catálogo v15)

La intervención recupera la degradación y mejora la robustez al viento máximo en 24 puntos (61 % → 85,5 %). Reentrenar desde un modelo que ya sabe usar la abertura reduce la variabilidad entre semillas (±1,0 frente a ±4,4).

Lo que aprendimos, en orden

1. La parametrización de la acción decide si PPO aprende (0 % → 97 % sin tocar el ambiente).
2. La transferencia desde el nivel anterior es lo que hace abordables los niveles 2 y 3 con 1,5 M de pasos (8 % desde cero frente a 86 % con transferencia).
3. Cuando el obstáculo cambia qué significa "objetivo", hay que dárselo al agente en la observación (2 % → 96 %).
4. La variabilidad entre semillas llega a 4 puntos: por eso se reportan medias y el pipeline conserva recomendado y anterior.
5. Partir del mejor modelo del nivel anterior importa más que el presupuesto (92 frente a 86,5 %; 97,5 frente a 94,5 %).

10. Cómo se evalúa y cómo se decide

- **Suite v1** (`configs/suites`): 200 épocas con semillas desde 10 000 000 (meteorología y salida que no aparecen en el entrenamiento, que usa otras semillas; la evaluación periódica usa 20 000 000), modelo congelado y sin ruido, en dos condiciones: normal (viento sorteado en el rango del ambiente) y **viento fijo de 15 m/s**. Las mismas 200 épocas para todos los modelos del mismo ambiente.
- **Métricas**: tasa de aterrizajes seguros (la de la misión), velocidad de contacto, error de posición final; complementarias: combustible, colisiones, cómo terminan las épocas, primer aterrizaje y mejor época durante el entrenamiento.
- **Criterio de aceptación del pipeline**, fijado antes de entrenar: un candidato sustituye al recomendado de su nivel si gana al menos **2 puntos** de tasa, no pierde más de **5 puntos** con viento de 15 m/s y **no tiene más colisiones**. En un nivel nuevo, la referencia es el modelo del nivel anterior jugando en él (`incidente.py`). El anterior se conserva para el rollback.
- **Test reservado** (`suite_reservada.py`): misma estructura, semilla guardada fuera del repositorio, aplicado **una sola vez** el 10 de noviembre a los tres recomendados: 97,5, 99,0 y 97,0 % (−1,5, −1 y −0,5 puntos respecto a la suite v1): no hay sobreajuste a la suite.
- **Viento en vivo** (web): no es un experimento ni un entrenamiento. La API simula paso a paso con el modelo congelado y el usuario mueve el viento; es la perturbación del nivel 3 aplicada a mano para verla.

11. Chuleta de números

Dato	Valor
Salida · plataforma · zona	600 m · radio 10 m · cilindro 300 × 1200 m
Aterrizaje seguro	|vz| ≤ 3 m/s, v_h ≤ 2 m/s, inclinación ≤ 10°, ≤ 10 m del centro
Paso del agente · física · límite	20 m o 2 s · Euler 0,1 s · 50 pasos (100 s)
Cohete	1000 kg + 500 kg de combustible, 27 kN, Isp 250 s, C_d 0,8, A 3 m², fuselaje 3 m
Viento	N1/N2: 0–10 m/s, ráfagas 1,5; N3: 0–15, ráfagas 3; perturbación: 15 fijo; perfil (z/10)^(1/7)
Recompensa	potencial −d/5 − v_h − |vz − v_seg| − z/10 (−8c); combustible −0,1/kg; +100 / −50 / −100
Pasarela	radio 90 m a 180 m, grosor 3 m, abertura r 16 m en (28, 12), 4 pilares r 2,5 m
Observación · acción	16 (N1) y 20 (pasarela) · 5 en el entorno, 3 en la red (relativa v2, inclinación ≤ 9,6°)
PPO	MLP 128×128, 8 envs, 2048 pasos/actualización, lr 3e-4, γ 0,99, λ 0,95, clip 0,2, ent 0,005
Presupuestos	600 000 pasos (N1) · 1 500 000 (N2, N3)

Dato	Valor
Ejecuciones · experimentos · pipeline	23 · 6 · 21 evidencias; catálogo v15
Recomendados (suite v1 / viento 15 / reservada)	N1 99 / 72 / 97,5 · N2 100 / 68 / 99 · N3 97,5 / 85,5 / 97
Medias de tres semillas	N1 97,8 ± 1,0 · N2 96,3 ± 4,4 · N3 93,7 ± 1,0
Degradación sin reentrenar	N1 bajo pasarela 99 → 5 % · N2 en N3 v1 100 → 93,5 % (s0: 91,5 → 64,5 %)
Criterio del pipeline	+2 puntos, viento −5 como mucho, no más colisiones

12. Preguntas que pueden hacer y la respuesta corta

- **¿Por qué el viento no es una fuerza?** Entra por el arrastre como velocidad del aire: su efecto depende de la densidad (temperatura y presión) y de la velocidad relativa. Así las tres variables meteorológicas están acopladas.
- **¿Por qué un potencial?** Para que la recompensa guíe sin cambiar la política óptima: sumada en la época solo depende de dónde empieza y dónde acaba; flotar no suma. El castigo de proximidad de la pasarela también va dentro del potencial.
- **¿Qué pasa si el agente no observa las ráfagas?** Es intencional: ve el viento en su posición (medio + ráfaga actual) y tiene que reaccionar; la dirección media la infiere.
- **¿Por qué 50 pasos?** Desde 600 m hacen falta 30 pasos de 20 m en línea recta; los 20 restantes son el margen para frenar y corregir. Con 800 m de salida no alcanzaba.
- **¿`terminated` o `truncated`?** Estados finales terminan; agotar pasos trunca con la misma penalización. Cambió en 0.1.1 sin invalidar modelos.
- **¿Por qué no torque?** Decisión documentada: el eje sigue al empuje. El torque real está en la lista de lo que haríamos después, como la abertura aleatoria por época.
- **¿Por qué el recomendado no es la media?** El pipeline promueve con un criterio fijo y conserva el anterior; la media de las tres semillas está en el informe y en las fichas; el test reservado confirma que no hay sobreajuste.
- **¿Cuál fue el experimento que más enseñó?** El 2: la misma red pasa de 0 % a 97 % cambiando solo cómo se expresa la acción.